

面向非接触式压力识别的区域-时间注意力多区域颜色脉动网络

匿名作者

匿名单位

摘要 压力往往先表现为生理变化，再表现为明显的面部表情或行为变化。基于普通摄像头的人脸视频压力识别具有非接触、低干扰的优势，但皮肤颜色变化微弱、区域分布不均，并容易受运动、光照和身份外观干扰。完整人脸帧建模可能在小规模数据上学习身份或场景捷径，先恢复全脸远程生理信号再分类又可能过早压缩区域差异。为此，本文提出区域-时间注意力多区域颜色脉动网络 RT-MRCPNet。RT-MRCPNet 将人脸视频片段转化为多个面部区域的颜色时序序列，将不同区域视为多路弱生理观测。模型使用共享时序编码器提取区域内部颜色动态，通过时间注意力选择每个区域中更可靠的片段，并通过区域注意力自适应融合不同面部区域，得到片段级压力表示。本文在社会压力人脸视频数据上采用跨被试协议进行实验，RT-MRCPNet 达到 86.42% 准确率、90.27% F1-score 和 93.07% 曲线下面积；相比多区域固定融合基线分别提升 5.70、4.60 和 3.95 个百分点。实验结果表明，自适应时间和区域加权优于全脸颜色序列、单区域序列、传统远程光电容积脉搏波特征和轻量神经网络基线。

Keywords: 非接触式压力识别 · 多区域颜色时序 · 区域-时间注意力 · 生理视觉表示 · 跨被试评估

1 引言

压力识别真正有价值的场景，往往不在实验室里。在线面试、远程学习、远程医疗和日常工作负荷监测都需要低干扰、易部署的感知方式，而被试通常不可能长期佩戴心电电极、皮肤电传感器、光电容积脉搏波夹或呼吸带。普通摄像头提供了一种自然的非接触式信号来源：人脸视频不仅记录表情、视线和头部运动，也包含由血容量变化引起的微弱皮肤颜色波动。已有研究表明，这类颜色波动可用于远程估计心率、呼吸和心率变异性等生理指标，并进一步支持认知压力或情绪状态分析 [1–3]。UBFC-Phys [4]、StressID [5] 和 ForDigitStress [6] 等数据集进一步将人脸视频放入社会压力或数字交互

协议中，并同步采集接触式生理信号、主观评分或任务标签。因此，基于人脸视频的非接触式压力识别具有明确应用价值，但其关键困难在于压力相关颜色变化微弱、局部且容易被身份外观、运动和光照变化淹没。

现有人脸视频方法容易在“完整视觉建模”和“全局生理信号摘要”之间损失有效证据。完整视频模型保留丰富外观细节，DeepPhys [7]、PhysNet [8]、MTTS-CAN [9] 和 EfficientPhys [10] 等工作证明深度网络可以学习远程生理表示，但小规模压力数据使其容易学习身份、背景、肤色或任务场景等捷径。另一类流程通常先恢复全脸远程光电容积脉搏波（rPPG）信号，再分类心率或心率变异性特征；已有研究也沿着这一思路将普通摄像头恢复的远程生理指标用于压力相关分析 [1, 3]。然而，这种全局摘要可能过早压缩额头、脸颊、鼻部和下巴之间的差异。说话动作、表情变化、头发遮挡、眼镜反光、非对称光照和局部高光对不同面部区域的影响并不相同，某个区域在一个片段中可能稳定，在另一个片段中却可能充满噪声。多尺度 ROI 方法 [11]、GraphPhys [12] 以及面部区域作用研究 [13] 均表明不同面部区域的 rPPG 质量并不相同，因此非接触式压力识别需要一种紧凑且保留区域证据的表示。

另一个挑战是压力视频中时间位置和面部区域的可靠性会动态变化。DeepPhys [7]、MTTS-CAN [9] 和基于峰值注意力的压力识别方法 [14] 均使用注意力增强生理视频建模，说明输入自适应加权有助于抑制低质量线索。对于本文任务而言，说话、计算、眨眼、转头、遮挡、反光和非对称光照可能在不同时间污染不同区域，固定平均会把有效反应与噪声片段混合。将整个人脸看成一个平均信号，可能会把有用的局部颜色动态和低质量区域混在一起；将整个片段做统一时间聚合，也可能把短时有效反应与眨眼、转头或光照突变混在一起。因此，压力识别需要同时考虑时间可靠性和区域可靠性。不过，对于样本有限的压力数据集，轻量注意力设计比大规模 Transformer 式模型更适合。

本文提出 RT-MRCPNet，即区域-时间注意力多区域颜色脉动网络。该方法将面部区域视为多路弱生理观测源，直接从区域红绿蓝（RGB）动态中学习压力相关表示，并通过轻量注意力机制同时建模片段内的时间可靠性和不同区域的判别贡献。相比直接输入完整人脸帧或先恢复单一全脸生理信号，RT-MRCPNet 更强调保留局部颜色动态，并在分类阶段自适应选择更可靠的时间和区域证据。本文贡献如下：

- 将视频压力识别建模为多区域颜色脉动序列学习问题，保留全脸平均信号中容易丢失的 ROI 级 RGB 动态。
- 设计轻量区域-时间注意力网络，分别建模区域内部的时间可靠性和区域之间的判别贡献。
- 在 UBFC-Phys 跨被试 (subject-independent) 协议下验证方法，RT-MRCPNet 达到 86.42% 准确率 (ACC)、90.27% F1-score 和 93.07% 曲线下面积 (AUC)，优于全脸 RGB、单区域、多区域固定融合、传统 rPPG 特征和轻量视频基线。

2 相关工作

2.1 压力识别与多模态数据

压力识别长期依赖心电、皮肤电、光电容积脉搏波、呼吸和皮肤温度等接触式生理信号，因为它们接近压力反应机制 [15–17]。心率变异性描述自主神经调节，皮肤电反映交感唤醒，呼吸节律也会随认知负荷变化，但这些传感器需要佩戴、同步和用户配合 [16, 18]。在远程面试、在线学习或日常工作场景中，传感器本身还可能改变被试行为，从而削弱生态有效性。因此，近年数据集开始走向更真实的多模态场景：UBFC-Phys 在静息、演讲和算术任务中采集人脸视频以及腕带血容量脉搏和皮肤电 (EDA) [4]；StressID 在情绪、认知和公开演讲刺激下记录视频、音频、心电、EDA 和呼吸 [5]；ForDigitStress 面向数字化面试，包含视频、眼动、音频、光电容积脉搏波和 EDA [6]。这些数据集推动了非接触式压力识别，也说明高质量压力数据仍然规模有限且依赖具体协议。对这类数据而言，模型不仅需要利用多模态或视频信息，还需要避免在 subject-independent 评估中依赖身份外观和协议背景等捷径。

2.2 非接触式压力识别与人脸颜色线索

早期非接触式研究通常先从人脸视频估计远程生理指标，再用于分类。McDuff 等 [1] 利用视频估计心率、呼吸和心率变异性 (HRV) 并进行认知压力分类；Nikolaiev 等 [3] 从普通摄像头 rPPG 中恢复 HRV 指标；Benezeth 等 [2] 探索远程 HRV 在情绪监测中的作用。这些工作证明普通摄像头并非只能记录外观，也可以捕获与压力相关的弱生理变化。近期工作开始转向直接视频学习：Xu 等 [14] 使用多任务学习和峰值注意力进行人脸视频压力识

别, SympCam [19] 及相关研究 [20] 则从面部和手部视频估计交感唤醒。这些研究表明, 压力识别与 rPPG 相关, 但并不等同于恢复一条干净脉搏波; 判别线索可能表现为局部颜色动态、短时峰值、外周血流变化或任务诱发的说话和运动。因此, 模型不应只追求一条全局生理信号, 而应保留更细粒度的区域级时间证据。

传统 rPPG 方法如 CHROM [21]、POS [22] 和 LGI [23] 说明 RGB 轨迹包含弱心血管信息; DeepPhys [7]、PhysNet [8]、MTTS-CAN [9] 和 EfficientPhys [10] 进一步从视频时空变化中学习生理证据。不过, 这些方法通常以生命体征估计为目标, 评价重点是波形质量或心率误差; 压力识别更关注心理或社会任务诱发的判别模式。因而, 本文不把人脸颜色线索仅视为待重建的全局脉搏波, 而是将其作为可直接服务于压力分类的区域级时间证据。

2.3 多区域建模与注意力机制

面部区域选择是 rPPG 质量的关键因素, 因为局部血流、皮肤纹理、姿态、光照和运动会导致不同 ROI 的信噪比差异。多尺度和多 ROI 方法可以提升心率估计鲁棒性 [11], 近期研究也指出区域选择仍是开放问题, 而不是一个已经解决的预处理细节 [13]。GraphPhys 则用图神经网络建模面部区域关系, 并强调不同面部区域之间的生理一致性和互补性 [12]。这些研究支持一个基本判断: 面部区域信息不应在模型早期被过度压缩。

注意力机制同样常用于抑制背景或不可靠帧, 并突出有效波形片段。空间注意力可以降低背景和非皮肤区域影响, 时间注意力可以强调可靠帧或有效波形片段, 通道注意力可以建模颜色通道或特征维度之间的关系 [7, 9, 14]。近年来, PhysFormer [24]、RhythmFormer [25] 和 Masked Attention Regularization [26] 进一步说明注意力机制可用于增强远程生理时空表征。然而, 现有注意力设计多服务于完整视频表征或远程生理重建。本文关注的是更聚焦的问题: 能否使用紧凑区域颜色序列, 并通过两个轻量注意力阶段分别完成区域内部时间聚合和区域之间贡献融合, 从而提升 subject-independent 压力识别。这样的设计不追求重建最干净的远程脉搏波, 而是直接面向压力分类学习区域颜色动态。

3 方法

3.1 问题定义

给定人脸视频片段 $V = \{I_1, I_2, \dots, I_T\}$, 其中 T 表示片段帧数, 目标是预测二分类标签 $y \in \{0, 1\}$, 其中 0 表示非压力, 1 表示压力。本文不将完整帧序列直接输入大型视频网络, 而是先将视频转化为多区域颜色脉动表示:

$$X \in \mathbb{R}^{K \times T \times C}, \quad (1)$$

其中 K 表示面部区域数量, T 表示片段长度, $C = 3$ 表示 RGB 三个颜色通道。对于一个 batch, 模型输入为 $X \in \mathbb{R}^{B \times K \times T \times C}$ 。该表示将空间维度压缩到少量 ROI, 同时保留每个区域随时间变化的颜色动态。

3.2 多区域颜色脉动表示

对于每一帧, 首先检测、裁剪并缩放人脸, 使固定 ROI 在不同帧间保持几何一致。图 1 展示了本文使用的五个区域: 额头、左脸颊、右脸颊、鼻部和下巴。它们覆盖 rPPG 常用皮肤区域, 同时具有不同可靠性: 脸颊通常包含较清晰的颜色动态, 额头较稳定但可能受头发影响, 鼻部易受高光影响, 下巴易受说话动作干扰。本文采用固定矩形区域而不是密集 landmarks, 一方面降低预处理复杂度, 另一方面使不同视频片段中的区域定义保持一致。

对于第 k 个区域在第 t 帧上的 RGB 向量, 本文使用区域内所有像素的平均值:

$$x_{k,t} = \frac{1}{|\Omega_k|} \sum_{p \in \Omega_k} I_t(p), \quad (2)$$

其中 Ω_k 表示第 k 个区域的像素集合。第 k 个区域的颜色序列可以表示为

$$X_k = [x_{k,1}, x_{k,2}, \dots, x_{k,T}]. \quad (3)$$

将所有区域序列堆叠后得到 $X \in \mathbb{R}^{K \times T \times C}$, 其中 $C = 3$, 对应 RGB 三个颜色通道。

本文对每个区域、每个颜色通道分别进行时间维度标准化:

$$\hat{X}_{k,:,c} = \frac{X_{k,:,c} - \mu_{k,c}}{\sigma_{k,c} + \epsilon}. \quad (4)$$

其中, c 为颜色通道索引, $X_{k,:,c}$ 表示第 k 个区域在第 c 个颜色通道上的完整时间序列, $\mu_{k,c}$ 和 $\sigma_{k,c}$ 为片段内均值和标准差, ϵ 防止除零。该步骤降低个体肤色、相机曝光和整体亮度偏移的影响。与直接使用原始帧相比, 该表示去除大部分空间冗余, 同时保留区域颜色动态。




图 1. 本文多区域颜色脉动表示使用的五个面部区域。归一化人脸被划分为额头、左脸颊、右脸颊、鼻部和下巴五个 ROI，每个区域进一步转换为 RGB 颜色时序序列。

3.3 区域时序编码器

每个区域序列由共享的一维时序编码器进行编码。给定标准化张量 $\hat{X}$ ，先将其调整为 $\tilde{X} \in \mathbb{R}^{BK \times C \times T}$ ，再输入多层一维卷积块：

$$H = E_{\theta}(\tilde{X}), \quad (5)$$

经过维度调整后， $H \in \mathbb{R}^{BK \times T \times D}$ ，其中 D 为隐藏维度。共享编码器可以捕获不同区域共有的低层颜色动态，同时降低参数量和过拟合风险；短时间卷积核则用于建模局部变化，而无需反复处理完整空间图像网格。

这种先压缩空间、再建模时间的方式使模型容量集中在颜色动态和区域融合上。与三维卷积或完整帧循环网络相比，输入规模不随图像面积线性增长，更适合小规模 subject-independent 压力识别实验。

3.4 时间注意力

对于第 k 个区域的时序特征，时间注意力为每个时间位置预测一个分数：

$$e_{k,t} = \mathbf{w}_t^T \tanh(\mathbf{W}_t h_{k,t}), \quad (6)$$

其中 $\mathbf{W}_t$ 为时间注意力中的特征投影矩阵, $\mathbf{w}_t$ 为用于生成标量分数的权重向量, $h_{k,t} \in \mathbb{R}^D$ 为第 k 个区域在第 t 个时间位置的特征。归一化后的时间权重为

$$\alpha_{k,t} = \frac{\exp(e_{k,t})}{\sum_{\tau=1}^T \exp(e_{k,\tau})}. \quad (7)$$

区域级表示通过加权求和得到:

$$r_k = \sum_{t=1}^T \alpha_{k,t} h_{k,t}. \quad (8)$$

这样, 每个区域拥有独立时间权重, 可以在区域融合前抑制说话、运动或光照造成的不稳定片段。该顺序很重要: 说话动作可能更明显地影响下巴, 反光可能更多影响鼻部, 而额头和脸颊受到的干扰模式并不完全相同。

3.5 区域注意力

完成时间聚合后, 模型得到区域级表示 $\{r_1, \dots, r_K\}$ 。区域注意力首先为每个区域计算贡献分数:

$$s_k = \mathbf{w}_r^\top \tanh(\mathbf{W}_r r_k), \quad (9)$$

其中 $\mathbf{W}_r$ 为区域注意力中的特征投影矩阵, $\mathbf{w}_r$ 为用于生成区域标量分数的权重向量。然后通过 softmax 得到区域权重:

$$\beta_k = \frac{\exp(s_k)}{\sum_{j=1}^K \exp(s_j)}. \quad (10)$$

注意力融合后的片段级表示为

$$z_{\text{attn}} = \sum_{k=1}^K \beta_k r_k. \quad (11)$$

区域权重 β_k 反映当前片段中各 ROI 的相对贡献, 因此模型可以在不同被试、光照或任务阶段下自适应调整区域使用方式。为了提升训练稳定性, 本文加入平均区域表示作为残差项:

$$z = z_{\text{attn}} + \frac{1}{K} \sum_{k=1}^K r_k. \quad (12)$$

最终, z 输入两层多层感知机分类器, 得到 logits:

$$o = \text{MLP}(z). \quad (13)$$

图 2 总结了 RT-MRCPNet 的整体流程。




图 2. RT-MRCPNet 模型结构图。人脸视频片段首先被转换为多区域 RGB 颜色时序序列，经共享时序编码器提取区域动态特征，再通过时间注意力和区域注意力完成自适应聚合，最终输出压力/非压力分类结果。

3.6 训练目标

本文使用交叉熵损失训练模型。令 $p_c = \text{softmax}(o)_c$ 表示类别 c 的预测概率，则损失函数为

$$\mathcal{L}_{cls} = - \sum_{c=1}^2 y_c \log p_c, \quad (14)$$

其中 y_c 表示真实标签的 one-hot 编码在类别 c 上的取值。本文只使用分类监督，使比较聚焦于区域 RGB 动态和注意力聚合，避免将辅助重建或对比学习目标带来的影响混入主比较。

4 实验

4.1 数据集与标签定义

本文主要实验面向社会压力人脸视频数据。对于 UBFC-Phys 类型数据，每名被试包含静息、演讲和算术三个任务。按照常见社会压力协议解释，静息任务被视为非压力状态，演讲和算术任务被视为压力状态：

$$T1 = 0, \quad T2/T3 = 1. \quad (15)$$

该二分类设定清晰、可复现，并与本文关注的问题一致：在不使用接触式传感器的情况下，视频模型能否区分静息片段和社会压力任务片段。

4.2 Subject-Independent 协议

所有实验均采用 subject-independent 划分，即同一被试的视频片段不能同时出现在训练集和测试集中。否则，模型可能学习到身份外观，而不是

压力相关动态。固定划分使用 70% 被试训练、15% 被试验证、15% 被试测试。验证集仅用于模型选择，测试集仅用于最终报告。由于小规模压力数据对被试划分较敏感，本文记录具体被试编号或随机种子，以保证实验可复现。

4.3 实现细节

人脸区域被裁剪并缩放到 128×128 。每个视频被划分为固定长度片段，默认片段长度为 $T = 160$ 。本文使用五个固定面部区域。对于每个区域，提取逐帧 RGB 均值序列并进行时间标准化。模型隐藏维度为 128，优化器为 AdamW，初始学习率为 10^{-3} ，batch size 为 64，论文主实验训练轮数为 30。模型根据验证集 F1-score 选择最优 checkpoint。实验在单张 RTX 5090 图形处理器和 PyTorch 环境中完成。

4.4 评价指标

本文报告 Accuracy、F1-score 和 AUC，并使用混淆矩阵展示最终模型的错误分布。考虑到压力识别任务可能存在类别不平衡，F1-score 和 AUC 比单独的 Accuracy 更重要。在二分类设置中，压力状态被视为正类。

4.5 对比实验

对比实验采用统一协议设置。在输入形式允许的情况下，所有对比方法均使用同一输入来源、同一 subject-independent 划分、同一片段构造方式和同一评价代码。统一协议下的对比方法用于回答一个更具体的问题：当输入都限制为人脸 RGB 视频时，多区域时序表示和注意力融合是否真正有效。本文的对比方法从简单颜色序列基线逐步扩展到视频时序模型和 rPPG 相关模型。

- 全脸 RGB 时序网络：将五个区域序列先平均为一个全脸级 RGB 序列，再进行时序编码。
- 单区域 RGB 时序网络：分别使用额头、左脸颊、右脸颊、鼻部和下巴区域，用于观察不同面部区域的识别差异。
- 多区域固定融合：保留多个区域 RGB 序列，但使用非自适应拼接或平均融合，不使用注意力。

- 传统 rPPG 特征分类器：使用 POS [22] 或 CHROM [21] 从面部颜色轨迹中提取信号，再计算 HR/HRV 等手工特征，并使用支持向量机或随机森林分类。
- 轻量视频时序基线：使用紧凑 CNN-LSTM [27] 或 3D CNN [28] 直接输入裁剪后的人脸片段，输出压力类别。CNN-LSTM 类结构参考远程压力估计中的 CCT-LSTM 思路，3D CNN 类结构参考经典三维卷积视频建模方法。
- 已有 rPPG backbone 加压力分类头：将 PhysNet [8] 这个代表性 rPPG 模型的输出头替换为压力分类头。
- RT-MRCPNet：本文方法，使用多区域 RGB 序列，并通过时间注意力和区域注意力进行自适应融合。

表 1 表明，RT-MRCPNet 在所有受控基线中取得最高 ACC、F1-score 和 AUC。与全脸 RGB 时序网络相比，RT-MRCPNet 在 ACC、F1-score 和 AUC 上分别提升 4.18、2.71 和 5.87 个百分点；与多区域固定融合相比，三项提升分别为 5.70、4.60 和 3.95 个百分点。这说明性能提升不仅来自使用多个 ROI，也来自对可靠时间位置和判别性面部区域的自适应选择。单区域结果还显示出明显的区域差异：在该划分上，下巴和鼻部序列强于单独脸颊区域，但任一单区域模型都无法达到自适应多区域表示的性能。

图 3 展示了五个面部 ROI 的颜色脉动信号差异。不同区域在波动幅值、稳定性和受干扰程度上并不一致，这与表 1 中单区域模型性能差异相互印证，也说明简单全脸平均或固定区域融合容易丢失有效的局部证据。

图 4 进一步展示了注意力权重与输入可靠性之间的关系。时间注意力用于在片段内部区分相对稳定和受干扰的时间位置，区域注意力则用于反映不同面部区域对最终判别的相对贡献，从而解释 RT-MRCPNet 相比固定融合方法的优势。

4.6 消融实验

消融实验进一步拆解本文模型，并采用与表 1 相同的协议。与对比实验不同，主对比实验改变的是输入表示或融合策略；消融实验则从 RT-MRCPNet 内部移除具体注意力模块，用于检验每个组件是否对最终分类有贡献。

表 2 表明，时间注意力是该划分上更强的单独贡献项。移除两个注意力模块后，模型退化为固定多区域融合；加入时间注意力后，ACC、F1-score 和 AUC 均明显提升，而单独使用区域注意力只带来较小的 ACC 和 F1-score 增

表 1. UBFC-Phys subject-independent 统一协议下的对比实验。ACC 表示准确率, AUC 表示受试者工作特征曲线下面积, RGB 表示红绿蓝颜色通道。所有模型均只使用人脸 RGB 视频, 并采用相同片段长度、相同训练/验证/测试划分和相同评价代码。所有指标均以百分比 (%) 报告。

方法	输入	ACC	F1	AUC
全脸 RGB 时序网络	全脸平均 RGB 序列	82.24	87.56	87.20
额头单区域时序网络	额头 RGB 序列	75.21	82.06	79.36
左脸颊单区域时序网络	左脸颊 RGB 序列	73.88	80.76	77.15
右脸颊单区域时序网络	右脸颊 RGB 序列	64.20	76.09	59.82
鼻部单区域时序网络	鼻部 RGB 序列	78.35	83.74	85.96
下巴单区域时序网络	下巴 RGB 序列	80.72	86.05	85.40
多区域固定融合	五个 ROI RGB 序列, 固定融合	80.72	85.67	89.12
rPPG 特征 + 支持向量机	HR/HRV 手工特征	77.87	84.18	76.79
rPPG 特征 + 随机森林	HR/HRV 手工特征	77.02	84.43	75.60
轻量 CNN-LSTM	ROI RGB 时序张量	67.33	76.82	62.73
轻量 3D CNN	ROI RGB 时序张量	70.75	80.60	70.70
PhysNet + 压力分类头	全脸 RGB/rPPG 相关特征	80.63	86.61	87.64
RT-MRCPNet	五个 ROI RGB 序列, 注意力融合	86.42	90.27	93.07




图 3. 区域信号多样性可视化。该图展示不同面部区域的颜色脉动信号在幅值、形态和稳定性上的差异, 说明压力相关线索具有明显的区域不均匀性。




图 4. 注意力可靠性可视化。该图展示 RT-MRCPNet 在代表性片段上的时间注意力和区域注意力分布，用于观察模型是否能够降低不稳定时间段或低质量区域的影响，并突出更可靠的判别线索。

益。同时使用时间注意力和区域注意力时取得最高 ACC 和 F1-score，AUC 也接近仅时间注意力版本。这说明时间可靠性建模提供主要鲁棒性收益，区域注意力进一步改善最终判别能力。

表 2. RT-MRCPNet 消融实验。ACC 表示准确率，AUC 表示受试者工作特征曲线下面积，所有指标均以百分比（%）报告。

模型变体	ACC	F1	AUC
无注意力	80.72	85.67	89.12
仅时间注意力	85.57	89.78	93.16
仅区域注意力	81.10	85.69	88.84
完整 RT-MRCPNet	86.42	90.27	93.07

4.7 复杂度分析

RT-MRCPNet 使用紧凑的区域 RGB 序列，而不是完整人脸视频帧。对于长度为 T 、分辨率为 $H \times W$ 、颜色通道数为 C 的视频片段，完整帧模型的输入规模为 $\mathcal{O}(THWC)$ ；经过区域颜色池化后，RT-MRCPNet 只保留 K 个区域的均值颜色序列，输入规模降为 $\mathcal{O}(KTC)$ 。由于 $K \ll HW$ ，该表示在进入神经网络前显著降低了空间冗余。

设隐藏维度为 D ，一维卷积核大小为 q ，时序编码器层数为 L ，batch size 为 B 。共享时序编码器对 BK 条区域序列进行一维卷积，主要复杂度为 $\mathcal{O}(BKLTqD^2)$ ；时间注意力和区域注意力的额外开销为 $\mathcal{O}(BKTD+BKD)$ 。因此，RT-MRCPNet 的主要计算量随区域数 K 和片段长度 T 增长，而不直接随图像面积 HW 增长。

表 3 报告了代表性方法的参数量和平均前向推理时间。可以看出，RT-MRCPNet 的参数量与全脸 RGB 时序网络相当，明显低于 CNN-LSTM，同时保持在轻量级范围内。其推理时间高于全脸 RGB 和 PhysNet/EfficientPhys 分类头，主要原因是模型需要分别处理五个 ROI，并计算时间注意力和区域注意力；但该开销仍低于 0.1 ms，远小于常规视频预处理和人脸检测开销。与轻量 3D CNN 相比，RT-MRCPNet 在相近推理时间下避免了直接建模完整空间帧，将计算集中在区域颜色动态和自适应融合上，因此在复杂度和识别性能之间取得了更合理的折中。

表 3. 模型复杂度对比。推理时间表示每个片段的平均前向时间。

方法	参数量	推理时间
全脸 RGB 时序网络	0.069M	0.0243 ms
轻量 CNN-LSTM	0.146M	0.0439 ms
轻量 3D CNN	0.019M	0.0832 ms
PhysNet/EfficientPhys + 压力分类头	0.073M	0.0215 ms
RT-MRCPNet	0.069M	0.0817 ms

5 结论

本文提出 RT-MRCPNet，一种用于非接触式压力识别的轻量级区域-时间注意力网络。该方法将人脸视频转化为多区域 RGB 时序序列，使用共享编码器建模局部颜色动态，并通过时间注意力和区域注意力聚合信息。在 subject-independent 协议下，RT-MRCPNet 达到 86.42% ACC、90.27% F1-score 和 93.07% AUC。消融实验和复杂度分析表明，两个注意力阶段能够带来互补增益并保持较低计算开销。未来工作将探索自适应 ROI 定义、更细粒度压力标签和多模态融合。

参考文献

- McDuff, D., Gontarek, S., Picard, R.W.: Remote measurement of cognitive stress via heart rate variability. In: Proceedings of the Annual International Conference of the IEEE Engineering in Medicine and Biology Society. pp. 2957–2960 (2014). <https://doi.org/10.1109/EMBC.2014.6944243>
- Benezeth, Y., Li, P., Macwan, R., Nakamura, K., Gomez, R., Yang, F.: Remote heart rate variability for emotional state monitoring. In: Proceedings of the IEEE EMBS International Conference on Biomedical and Health Informatics. pp. 153–156 (2018)
- Nikolaiev, S., Telenyk, S., Tymoshenko, Y.: Non-contact video-based remote photoplethysmography for human stress detection. *Journal of Automation, Mobile Robotics and Intelligent Systems* **14**(2), 63–73 (2020). <https://doi.org/10.14313/JAMRIS/2-2020/21>
- Meziati Sabour, R., Benezeth, Y., De Oliveira, P., Chappe, J., Yang, F.: UBFC-Phys: A multimodal database for psychophysiological studies of social stress. *IEEE Transactions on Affective Computing* **14**(1), 622–636 (2023). <https://doi.org/10.1109/TAFFC.2021.3056960>
- Chaptoukaev, H., Strizhkova, V., Panariello, M., D'Alpaos, B., Reka, A., Manera, V., Thümmel, S., Ismailova, E., Evans, N.W.D., Brémond, F., Todisco, M., Zuluaga, M.A., Ferrari, L.M.: StressID: A multimodal dataset for stress identification. In: *Advances in Neural Information Processing Systems*. vol. 36 (2023)
- Heimerl, A., Prajod, P., Mertes, S., Baur, T., Kraus, M., Liu, A., Risack, H., Rohleder, N., André, E., Becker, L.: The ForDigitStress dataset: A multi-modal dataset for automatic stress recognition. *IEEE Transactions on Affective Computing* pp. 1–17 (2024). <https://doi.org/10.1109/TAFFC.2024.3501400>
- Chen, W., McDuff, D.: Deepphys: Video-based physiological measurement using convolutional attention networks. In: *Proceedings of the European Conference on Computer Vision*. pp. 356–373 (2018)
- Yu, Z., Li, X., Zhao, G.: Remote photoplethysmograph signal measurement from facial videos using spatio-temporal networks. In: *Proceedings of the British Machine Vision Conference*. pp. 1–12 (2019)
- Liu, X., Fromm, J., Patel, S., McDuff, D.: Multi-task temporal shift attention networks for on-device contactless vitals measurement. In: *Advances in Neural Information Processing Systems*. vol. 33, pp. 19400–19411 (2020)
- Liu, X., Hill, B., Jiang, Z., Patel, S., McDuff, D.: Efficientphys: Enabling simple, fast and accurate camera-based cardiac measurement. In: *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*. pp. 5008–5017 (2023)
- Zhao, Y., Li, B., Wang, R., Wang, Y., Yan, J., Liu, F.: Remote estimation of heart rate based on multi-scale facial ROIs. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops* pp. 388–389 (2020)
- Xiong, J., Ou, W., Liu, Z., Gou, J., Xiao, W., Liu, H.: Graphphys: Facial video-based physiological measurement with graph neural network. *Computers and Electrical Engineering* **113**, 109022 (2024). <https://doi.org/10.1016/j.compeleceng.2023.109022>
- Bondarenko, M., Menon, C., Elgendi, M.: The role of face regions in remote photoplethysmography for contactless heart rate monitoring. *npj Digital Medicine* **8**, 479 (2025). <https://doi.org/10.1038/s41746-025-01814-9>
- Xu, J., Song, C., Yue, Z., Ding, S.: Facial video-based non-contact stress recognition utilizing multi-task learning with peak attention. *IEEE Journal of Biomedical and Health Informatics* **28**(9), 5335–5346 (2024). <https://doi.org/10.1109/JBHI.2024.3412103>
- Healey, J.A., Picard, R.W.: Detecting stress during real-world driving tasks using physiological sensors. *IEEE Transactions on Intelligent Transportation Systems* **6**(2), 156–166 (2005). <https://doi.org/10.1109/TITS.2005.848368>
- Schmidt, P., Reiss, A., Duerichen, R., Marberger, C., Van Laerhoven, K.: Introducing WESAD, a multimodal dataset for wearable stress and affect detection. In: *Proceedings of the 20th ACM International Conference on Multimodal Interaction*. pp. 400–408 (2018). <https://doi.org/10.1145/3242969.3242985>
- Schmidt, P., Reiss, A., Duerichen, R., Van Laerhoven, K.: Wearable-based affect recognition: A review. *Sensors* **19**(19), 4079 (2019). <https://doi.org/10.3390/s19194079>
- Bota, P., Wang, C., Fred, A., Plácido da Silva, H.: Empathicschool: A multimodal dataset for real-time facial expressions and physiological data analysis under different stress conditions. *arXiv preprint arXiv:2209.13542* (2022)
- Braun, B., McDuff, D., Baltrusaitis, T., Strel, P., Moebus, M., Holz, C.: SympCam: Remote optical measurement of sympathetic arousal. In: *Proceedings of the IEEE-EMBS International Conference on Biomedical and Health Informatics*. p. 10913710 (2024). <https://doi.org/10.1109/BHI62660.2024.10913710>
- Braun, B., McDuff, D., Baltrusaitis, T., Holz, C.: Video-based sympathetic arousal assessment via peripheral blood flow estimation. *Biomedical Optics Express* **14**(12), 6607–6628 (2023). <https://doi.org/10.1364/BOE.507949>
- de Haan, G., Jeanne, V.: Robust pulse rate from chrominance-based rPPG. *IEEE Transactions on Biomedical Engineering* **60**(10), 2878–2886 (2013). <https://doi.org/10.1109/TBME.2013.2266196>
- Wang, W., den Brinker, A.C., Stuijk, S., de Haan, G.: Algorithmic principles of remote PPG. *IEEE Transactions on Biomedical Engineering* **64**(7), 1479–1491 (2017). <https://doi.org/10.1109/TBME.2016.2609282>
- Pilz, C.S., Zaunseder, S., Krajewski, J., Blazek, V.: Local group invariance for heart rate estimation from face videos in the wild. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops* pp. 1254–1262 (2018)

24. Yu, Z., Shen, Y., Shi, J., Zhao, H., Torr, P.H.S., Zhao, G.: Physformer: Facial video-based physiological measurement with temporal difference transformer. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. pp. 4186–4196 (2022)
25. Zou, B., Guo, Z., Chen, J., Ma, H.: Rhythmformer: Extracting patterned remote photoplethysmography signals based on periodic sparse attention. Pattern Recognition **164**, 111511 (2025). <https://doi.org/10.1016/j.patcog.2025.111511>
26. Zhao, P., Sun, Q., Tian, X., Yang, Y., Tao, S., Cheng, J., Chen, J.: Toward motion robustness: A masked attention regularization framework in remote photoplethysmography. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. pp. 7829–7838 (2024)
27. Ziaratnia, S.M., Demirel, H., Farah, K.: Multimodal deep learning for remote stress estimation using CCT-LSTM. In: Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision Workshops. pp. 8337–8342 (2024)
28. Tran, D., Bourdev, L., Fergus, R., Torresani, L., Paluri, M.: Learning spatiotemporal features with 3d convolutional networks. In: Proceedings of the IEEE International Conference on Computer Vision. pp. 4489–4497 (2015)