

面向非接触式压力识别的区域-时间注意力多区域颜色脉动网络

匿名作者

匿名单位

摘要 压力往往先表现为生理变化，然后才可能表现为明显的面部表情或行为变化。因此，基于普通摄像头的人脸视频压力识别具有很强的应用吸引力，但也面临一个核心困难：有用的皮肤颜色变化十分微弱，在面部不同区域上的分布并不均匀，并且容易被运动、光照和身份外观淹没。现有视频方法大多沿着两条路线展开：一类直接对完整人脸帧建模，另一类先恢复远程生理信号，再计算特征进行分类。前者在小规模压力数据集上容易学习到身份或场景捷径，后者则可能过早压缩区域差异。为此，本文提出区域-时间注意力多区域颜色脉动网络 RT-MRCPNet。该方法将人脸视频片段转化为多个面部区域的 RGB 颜色时序序列，将不同区域视为多路弱生理观测。模型使用共享时序编码器提取区域内部颜色动态，通过时间注意力选择每个区域中更可靠的片段，并通过区域注意力自适应融合不同面部区域，最终得到片段级压力表示。本文在社会压力人脸视频数据上采用 subject-independent 协议进行实验，RT-MRCPNet 达到 88.42% ACC、88.15% F1-score 和 91.54% AUC；相比最强轻量视频基线分别提升 1.89、2.27 和 2.33 个百分点，相比多区域固定融合基线分别提升 4.80、5.11 和 5.10 个百分点。

Keywords: 非接触式压力识别 · 人脸视频 · 远程光电容积脉搏波 · 颜色脉动序列 · 区域-时间注意力

1 引言

压力识别真正有价值的场景，往往不在实验室里。在线面试、远程学习、远程医疗和日常工作负荷监测都需要低打扰、易部署的感知方式，而被试通常不可能长期佩戴心电电极、皮肤电传感器、光电容积脉搏波夹或呼吸带。矛盾也正在这里：压力本质上与生理反应密切相关，接触式传感器能够稳定记录心率变异性、交感唤醒和呼吸变化；但在许多真实交互场景中，真正可用的设备只有普通摄像头。

人脸视频为这个矛盾提供了一个可能的入口。除了表情、视线和头部运动，人脸视频还包含由血容量变化引起的细微皮肤颜色波动。远程光电容积脉搏波研究已经表明，这些波动可以用于心率估计、心率变异性分析、情绪状态监测和压力相关推断 [15, 1, 17]。近年来，UBFC-Phys、StressID 和 ForDigitStress 等数据集进一步将人脸视频放入社会压力或数字交互协议中，并同步采集接触式生理信号、主观评分和任务标签 [16, 5, 8]。这说明普通摄像头中可能蕴含足以支持压力识别的生理证据；困难在于，这些证据非常弱、非常局部，也非常容易被无关变化混淆。

现有方法大体暴露出两类问题。完整视频模型保留了丰富视觉细节，但在压力数据集规模有限时，模型可能学习到被试身份、背景、肤色或任务场景，而不是压力相关动态。传统信号处理流程更可解释，通常先恢复一条全脸远程生理信号，再计算心率或心率变异性特征并训练分类器；但单一全局信号并不一定是压力识别的最佳摘要。说话动作、表情、头发遮挡、眼镜反光、非对称光照和局部高光对额头、脸颊、鼻部和下巴的影响并不相同。某个区域在一个片段中可能稳定，在另一个片段中却可能充满噪声。

本文围绕这个观察展开：将人脸看成一个平均信号，可能会把有用的局部颜色动态和不可靠区域混在一起；将整个片段做统一时间聚合，也可能把短时有效反应与眨眼、转头或光照突变混在一起。因此，本文将不同面部区域视为多路弱生理观测源。每个视频片段被表示为多条 RGB 颜色时序序列，模型只需要回答两个具体问题：每个区域中哪些时间位置更可靠，当前片段中哪些区域更值得信任。这个设计位于沉重完整视频建模和刚性的人工生理特征流程之间，更适合小规模社会压力数据上的 subject-independent 评估。

为此，本文提出 RT-MRCPNet，即区域-时间注意力多区域颜色脉动网络。该方法首先检测并裁剪人脸区域，然后将归一化人脸划分为多个固定区域，并计算每个区域在每一帧上的 RGB 均值，得到形状为 $K \times T \times 3$ 的紧凑输入表示，其中 K 表示面部区域数量， T 表示片段长度。随后，模型使用共享的一维时序编码器提取每个区域内部的颜色动态。时间注意力模块用于聚合每个区域中更有效的时间位置，区域注意力模块用于将区域级特征融合为片段级压力表示。

本文的主要贡献如下：

- 将非接触式压力识别建模为多区域颜色脉动序列学习问题，将人脸视频压缩为区域级 RGB 时序序列，而不是直接处理完整图像帧。

- 设计轻量级区域-时间注意力网络，分别建模区域内部的时间可靠性和区域之间的判别贡献。
- 在 UBFC-Phys 跨被试协议下验证本文方法，RT-MRCPNet 达到 88.42% ACC、88.15% F1-score 和 91.54% AUC，优于全脸 RGB、单区域、多区域固定融合、传统 rPPG 特征和轻量视频基线。

2 相关工作

2.1 压力识别与多模态压力数据集

压力识别长期以来主要依赖接触式生理信号。心电、皮肤电、光电容积脉搏波、呼吸和皮肤温度等模态之所以重要，是因为它们接近压力反应的生理机制。心率变异性能够描述自主神经调节，皮肤电常被视为交感唤醒的指标，呼吸节律也会随认知负荷和情绪紧张发生变化。这类方法在受控实验环境中可靠，但代价是传感器佩戴、同步采集和用户配合。对于远程面试或在线学习等自然场景，传感器本身就可能改变被试表现。

近几年的数据集体现出一个清晰趋势：压力识别正在从单一接触式传感器走向更真实的多模态场景。UBFC-Phys 在静息、演讲和算术任务中采集人脸视频，同时记录腕带血容量脉搏和皮肤电信号 [16]。StressID 包含 65 名被试在情绪视频、认知任务和公开演讲等多种刺激下的面部视频、音频、心电、皮肤电和呼吸信号 [5]。ForDigitStress 面向数字化求职面试场景，包含视频、面部 landmarks、眼动、音频、光电容积脉搏波和皮肤电等信息 [8]。这些数据集重要的地方不只是模态更多，而是它们把压力识别放回了真实交互过程：说话、计算、表情变化和姿态变化都不再是可以简单剔除的噪声。与此同时，它们也提醒我们，高质量压力数据集规模有限，任务协议差异较大，因此模型设计需要兼顾紧凑性、可复现性和 subject-independent 泛化能力。

2.2 基于人脸视频的非接触式压力识别

早期非接触式压力研究通常将远程生理信号作为中间表示。McDuff 等人 [15] 证明，可以从人脸视频中估计心率、呼吸和心率变异性等生理参数，并用于认知压力分类。Nikolaiev 等人 [17] 进一步研究了基于普通摄像头视频的远程光电容积脉搏波压力检测流程，并从视频中恢复心率变异性指标。Benezeth 等人 [1] 探索了远程心率变异性在情绪状态监测中的应用。这些工

作给出了关键证据：普通摄像头并非只能记录外观，也可以捕获与压力相关的弱生理变化。

近年来，相关工作开始从“先估计生理指标再分类”转向直接视频学习。Xu 等人 [21] 提出基于多任务学习和峰值注意力的非接触式压力识别方法，说明面向压力任务的注意力机制已经成为一个重要方向。SympCam [4] 及其相关研究 [3] 则利用面部和手部视频远程估计交感唤醒，并用于身体压力检测。这些研究表明，压力识别不是简单的心率估计问题。判别证据可能表现为局部颜色动态、短时峰值、外周血流变化，也可能混入任务诱发的说话和运动模式中。因此，模型不应只追求一条“最干净”的全局脉搏波，而应保留区域级时间证据，并学习如何在当前片段中使用这些证据。

2.3 人脸视频远程生理测量

远程生理测量为非接触式压力识别提供了技术基础。传统远程光电容积脉搏波算法通常通过颜色空间投影、盲源分离或局部一致性建模抑制光照和运动干扰，代表性方法包括 CHROM [7]、POS [19] 和 LGI [18]。这些方法效率高、解释性强，但性能依赖皮肤区域分割、光照假设和后处理策略。

深度学习方法则尝试从视频中自动学习时空表示。DeepPhys [6] 引入卷积注意力机制进行视频生理测量；PhysNet [22] 使用时空网络恢复远程脉搏信号；MTTS-CAN [12] 利用多任务时序移位注意力同时估计心血管和呼吸相关信号；EfficientPhys [13] 进一步强调简单、快速的摄像头心脏测量。近年来，Transformer 和序列模型也被广泛引入。PhysFormer 通过时间差分 Transformer 建模远程生理信号 [23]；RhythmFormer 利用周期稀疏注意力挖掘远程脉搏信号的周期性 [26]；Masked Attention Regularization 面向运动鲁棒性改进远程生理测量 [24]；PhysMamba、MultiPhys 和 DualPhysMamba 等方法进一步探索状态空间模型和混合序列结构在长序列生理建模中的效率 [14, 9, 11]；FactorizePhys 则研究远程生理感知中的多维注意力建模 [10]。

这些研究为本文提供了重要参考，但它们的主要目标通常是生命体征估计，而不是压力分类。生命体征估计更关注波形保真度和心率误差，压力识别则更关注心理或社会任务下的判别模式。对于小规模二分类压力数据集，完整视频生理模型可能过重；而完全依赖人工特征的流程又可能丢失区域差异。本文选择介于两者之间的路线：保留紧凑的区域颜色时序表示，同时以端到端方式学习时间和区域聚合。

2.4 多区域建模与注意力机制

面部区域选择是远程生理测量中的关键问题。不同区域由于局部血流、皮肤纹理、姿态、光照和面部运动不同，信号质量存在明显差异。已有多尺度或多区域方法利用空间多样性提升心率估计鲁棒性 [25]。近期关于面部区域作用的系统研究也指出，区域选择仍然是远程生理测量中的开放问题，而不是一个已经解决的预处理细节 [2]。GraphPhys 进一步使用图神经网络建模不同面部区域之间的关系，并强调同一个体不同面部区域生理信号之间的一致性 [20]。这些研究支持一个基本判断：面部区域信息不应在模型早期被过度压缩。

注意力机制同样广泛用于生理视频分析。空间注意力可以抑制背景和非皮肤区域，时间注意力可以强调可靠帧或有效波形片段，通道注意力可以建模颜色通道或特征维度之间的关系。在压力识别中，注意力尤其有用，因为视频片段的标签可能由短时但关键的阶段决定，例如演讲中的高负荷片段、算术任务中的努力阶段或短暂唤醒变化。不过，小数据集上不能盲目使用大规模 Transformer。更务实的选择是只在区域特征和时间特征上使用轻量注意力，从而获得自适应融合能力，同时控制参数量。

2.5 本文方法定位

本文并不试图在远程脉搏波重建误差上与大型模型竞争，而是回答一个更聚焦的问题：在 subject-independent 压力识别中，紧凑的区域颜色表示能否比全脸平均或单一区域表示提供更稳健的判别信息？本文方法与已有研究的区别主要体现在三个方面。第一，本文不将整张人脸视为单一全局信号，而是将多个面部区域作为独立颜色时序观测源。第二，本文不以重建高保真远程脉搏波形作为最终目标，而是直接面向压力分类学习区域颜色动态。第三，本文采用两个轻量注意力阶段：一个用于区域内部的时间聚合，一个用于区域之间的贡献融合。这样的设计在保持模型容量可控的同时，提高了多区域证据在 subject-independent 压力识别中的利用效率。

3 方法

3.1 问题定义

给定一个人脸视频片段 $V = \{I_1, I_2, \dots, I_T\}$ ，其中 T 表示帧数，目标是预测二分类压力标签 $y \in \{0, 1\}$ 。其中，0 表示非压力状态，1 表示压力状

态。本文不将完整视频帧序列直接输入大型视频网络，而是将视频转化为多区域颜色脉动表示：

$$X \in \mathbb{R}^{K \times T \times C}, \quad (1)$$

其中 K 表示面部区域数量， $C = 3$ 表示 RGB 三个颜色通道。对于一个 batch，模型输入为 $X \in \mathbb{R}^{B \times K \times T \times C}$ 。




图 1. RT-MRCPNet 模型结构图。人脸视频片段首先被转换为多区域 RGB 颜色时序序列，经共享时序编码器提取区域动态特征，再通过时间注意力和区域注意力完成自适应聚合，最终输出压力/非压力分类结果。

3.2 多区域颜色脉动表示

对于每一帧图像，首先检测并裁剪人脸区域，然后将裁剪后的人脸缩放到固定分辨率，使预定义区域在不同帧之间保持几何一致。本文使用五个面部区域：额头、左脸颊、右脸颊、鼻部和下巴。这些区域无需复杂 landmarks 即可提取，并覆盖了远程生理测量中常用的面部皮肤区域。其中，额头通常较稳定但可能受头发和高光影响，左右脸颊通常包含较明显的皮肤颜色动态，鼻部位于人脸中心但容易受到运动和反光影响，下巴则提供下半脸观测但可能受到说话动作干扰。

对于第 k 个区域在第 t 帧上的 RGB 向量，本文使用区域内所有像素的平均值：

$$x_{k,t} = \frac{1}{|\Omega_k|} \sum_{p \in \Omega_k} I_t(p), \quad (2)$$

其中 Ω_k 表示第 k 个区域的像素集合。第 k 个区域的颜色序列可以表示为

$$X_k = [x_{k,1}, x_{k,2}, \dots, x_{k,T}]. \quad (3)$$




图 2. 本文多区域颜色脉动表示使用的五个面部区域。归一化人脸被划分为额头、左脸颊、右脸颊、鼻部和下巴五个 ROI，每个区域进一步转换为 RGB 颜色时序序列。

将所有区域序列堆叠后得到 $X \in \mathbb{R}^{K \times T \times 3}$ 。

为了降低个体肤色、曝光和视频亮度差异，本文对每个区域、每个颜色通道分别进行时间维度标准化：

$$\hat{X}_{k,:,c} = \frac{X_{k,:,c} - \mu_{k,c}}{\sigma_{k,c} + \epsilon}. \quad (4)$$

其中， $\mu_{k,c}$ 和 $\sigma_{k,c}$ 分别表示第 k 个区域第 c 个通道在整个片段上的均值和标准差。该表示去除了完整视频帧中的大部分空间冗余，同时保留了区域级颜色动态。

3.3 区域时序编码器

每个区域序列由共享的一维时序编码器进行编码。对于一个批量输入，首先将多区域张量展开为 $(BK) \times C \times T$ ，然后输入由多层一维卷积构成的时序编码器：

$$H = E_{\theta}(X), \quad (5)$$

经过维度调整后得到 $H \in \mathbb{R}^{BK \times T \times D}$ ，其中 D 为隐藏维度。所有区域共享同一个编码器有两个原因。第一，不同面部区域的低层颜色时序变化具有相

似结构。第二，共享参数可以降低模型复杂度，减少小规模压力数据上的过拟合风险。

该编码器采用较短的时间卷积核，用于捕获局部变化和平滑趋势。与完整三维卷积视频网络不同，本文不在原始空间图像网格上进行重计算，而是先将空间信息压缩为区域序列，再重点建模时间动态和区域融合。

3.4 时间注意力

一个视频片段中的所有时间位置并不等价。在社会压力任务中，被试可能说话、计算、眨眼或转头。部分时间位置包含稳定颜色动态，部分时间位置则可能受到运动或光照污染。对于第 k 个区域的时序特征，时间注意力为每个时间位置预测一个分数：

$$e_{k,t} = \mathbf{w}_t^\top \tanh(\mathbf{W}_t h_{k,t}), \quad (6)$$

其中 $h_{k,t}$ 表示第 k 个区域在第 t 个时间位置的编码特征。归一化后的时间权重为

$$\alpha_{k,t} = \frac{\exp(e_{k,t})}{\sum_{\tau=1}^T \exp(e_{k,\tau})}. \quad (7)$$

区域级表示通过加权求和得到：

$$r_k = \sum_{t=1}^T \alpha_{k,t} h_{k,t}. \quad (8)$$

这样，每个区域都拥有独立的时间权重。该设计很重要，因为说话动作可能更多影响下巴，反光可能更多影响鼻部，而额头和脸颊受到的干扰并不相同。

3.5 区域注意力

完成时间聚合后，模型得到区域级表示 $\{r_1, \dots, r_K\}$ 。区域注意力首先为每个区域计算贡献分数：

$$s_k = \mathbf{w}_r^\top \tanh(\mathbf{W}_r r_k), \quad (9)$$

然后通过 softmax 得到区域权重：

$$\beta_k = \frac{\exp(s_k)}{\sum_{j=1}^K \exp(s_j)}. \quad (10)$$

注意力融合后的片段级表示为

$$z_{\text{attn}} = \sum_{k=1}^K \beta_k r_k. \quad (11)$$

为了提升训练稳定性，本文加入平均区域表示作为残差项：

$$z = z_{\text{attn}} + \frac{1}{K} \sum_{k=1}^K r_k. \quad (12)$$

最终， z 被输入两层 MLP 分类器，得到压力分类 logits：

$$\hat{y} = \text{MLP}(z). \quad (13)$$

3.6 训练目标

本文使用交叉熵损失训练模型：

$$\mathcal{L}_{cls} = - \sum_{c=1}^2 y_c \log p_c, \quad (14)$$

其中 p_c 表示类别 c 的预测概率。本文只使用分类监督，使实验重点集中在区域 RGB 动态和注意力聚合对压力分类的贡献上，避免将辅助重建或对比学习带来的影响混入主比较。

4 实验

4.1 数据集与标签定义

本文主要实验面向社会压力人脸视频数据。对于 UBFC-Phys 类型数据，每名被试包含静息、演讲和算术三个任务。按照常见社会压力协议解释，静息任务被视为非压力状态，演讲和算术任务被视为压力状态：

$$T1 = 0, \quad T2/T3 = 1. \quad (15)$$

该二分类设定清晰、可复现，并与本文关注的问题一致：在不使用接触式传感器的情况下，视频模型能否区分静息片段和社会压力任务片段。

4.2 Subject-Independent 协议

所有实验均采用 subject-independent 划分，即同一被试的视频片段不能同时出现在训练集和测试集中。否则，模型可能学习到身份外观，而不是压力相关动态。固定划分使用 70% 被试训练、15% 被试验证、15% 被试测试。

验证集仅用于模型选择，测试集仅用于最终报告。由于小规模压力数据对被试划分较敏感，本文记录具体被试编号或随机种子，以保证实验可复现。

4.3 实现细节

人脸区域被裁剪并缩放到 128×128 。每个视频被划分为固定长度片段，默认片段长度为 $T = 160$ 。本文使用五个固定面部区域。对于每个区域，提取逐帧 RGB 均值序列并进行时间标准化。模型隐藏维度为 128，优化器为 AdamW，初始学习率为 10^{-3} ，batch size 为 64，训练轮数为 100。模型根据验证集 F1-score 选择最优 checkpoint。模型使用 PyTorch 2.1 在单张 NVIDIA GeForce RTX 3090 GPU 上训练，总训练时间约为 1.50 小时。

4.4 评价指标

本文报告 Accuracy、F1-score 和 AUC，并使用混淆矩阵展示最终模型的错误分布。考虑到压力识别任务可能存在类别不平衡，F1-score 和 AUC 比单独的 Accuracy 更重要。在二分类设置中，压力状态被视为正类。

4.5 对比方法

主对比实验采用统一协议设置。在输入形式允许的情况下，所有对比方法均使用同一输入来源、同一 subject-independent 划分、同一片段构造方式和同一评价代码。统一协议下的对比方法用于回答一个更具体的问题：当输入都限制为人脸 RGB 视频时，多区域时序表示和注意力融合是否真正有效。本文的对比方法从简单颜色序列基线逐步扩展到视频时序模型和 rPPG 相关模型。

- 全脸 RGB 时序网络：将五个区域序列先平均为一个全脸级 RGB 序列，再进行时序编码。
- 单区域 RGB 时序网络：分别使用额头、左脸颊、右脸颊、鼻部和下巴区域，用于观察不同面部区域的识别差异。

- 多区域固定融合：保留多个区域 RGB 序列，但使用非自适应拼接或平均融合，不使用注意力。
- 传统 rPPG 特征分类器：从面部颜色轨迹中提取 POS 或 CHROM 风格信号，再计算 HR/HRV 等手工特征，并使用 SVM 或随机森林分类。
- 轻量视频时序基线：使用紧凑 CNN-LSTM 或 3D CNN 直接输入裁剪后的人脸片段，输出压力类别。
- 已有 rPPG backbone 加压力分类头：将 PhysNet 或 EfficientPhys 等代表性 rPPG 模型的输出头替换为压力分类头。
- RT-MRCPNet：本文方法，使用多区域 RGB 序列，并通过时间注意力和区域注意力进行自适应融合。

表 1. UBFC-Phys subject-independent 统一协议下的对比实验。ACC 表示准确率，AUC 表示受试者工作特征曲线下面积，RGB 表示红绿蓝颜色通道。所有模型均只使用人脸 RGB 视频，并采用相同片段长度、相同训练/验证/测试划分和相同评价代码。所有指标均以百分比（%）报告。

方法	输入	ACC	F1	AUC
全脸 RGB 时序网络	全脸平均 RGB 序列	81.42	80.85	84.51
额头单区域时序网络	额头 RGB 序列	79.80	78.64	82.05
左脸颊单区域时序网络	左脸颊 RGB 序列	82.55	81.72	85.23
右脸颊单区域时序网络	右脸颊 RGB 序列	82.14	81.48	84.81
鼻部单区域时序网络	鼻部 RGB 序列	76.40	75.12	79.55
下巴单区域时序网络	下巴 RGB 序列	77.85	76.50	80.12
多区域固定融合	五个 ROI RGB 序列，固定融合	83.62	83.04	86.44
rPPG 特征 + SVM	HR/HRV 手工特征	78.50	77.25	81.33
rPPG 特征 + 随机森林	HR/HRV 手工特征	80.25	79.52	83.10
轻量 CNN-LSTM	裁剪人脸片段	84.20	83.55	87.12
轻量 3D CNN	裁剪人脸片段	85.15	84.78	88.02
PhysNet/EfficientPhys + 压力分类头	人脸片段或 rPPG 相关特征	86.53	85.88	89.21
RT-MRCPNet	五个 ROI RGB 序列，注意力融合	88.42	88.15	91.54

表 1 和图 3 表明，RT-MRCPNet 在 RGB 序列、传统 rPPG 特征和轻量视频基线中取得最佳结果。左右脸颊单区域模型优于鼻部和下巴区域，说




图 3. Subject-independent 评估的量化可视化。该图展示本文方法与代表性基线的 ROC 曲线，以及 RT-MRCPNet 的混淆矩阵，从而配合表 1 中的数值结果，直观呈现分类边界和错误分布。

明不同面部区域的信号质量并不均匀。RT-MRCPNet 进一步优于多区域固定融合，说明其收益不仅来自使用更多 ROI，也来自时间位置和面部区域的自适应加权。

4.6 消融实验

消融实验进一步拆解本文模型，并采用与表 1 相同的协议。与主对比实验不同，主对比实验改变的是输入表示或融合策略；消融实验则从 RT-MRCPNet 内部移除具体注意力模块，用于检验每个组件是否对最终分类有贡献。

表 2. RT-MRCPNet 消融实验。ACC 表示准确率，AUC 表示受试者工作特征曲线下面积，所有指标均以百分比 (%) 报告。

模型变体	ACC	F1	AUC
无注意力	83.62	83.04	86.44
仅时间注意力	86.15	85.52	88.90
仅区域注意力	85.34	84.71	88.22
完整 RT-MRCPNet	88.42	88.15	91.54

表 2 表明两个注意力阶段具有互补作用。移除两个注意力模块后，模型退化为固定多区域融合；单独加入时间注意力或区域注意力均能提升性能，同时使用二者时取得最佳结果。




图 4. 注意力可解释性可视化。该图用于展示五个面部区域上的区域注意力，以及代表性压力和非压力片段的时间注意力曲线，从而检查模型是否关注生理上合理的区域，并抑制不稳定时间片段。

4.7 复杂度分析

RT-MRCPNet 使用紧凑的区域 RGB 序列，而不是完整人脸视频帧。其输入规模为 $K \times T \times 3$ ，远小于完整视频模型的 $T \times H \times W \times 3$ 。表 3 报告了代表性方法的参数量、FLOPs 和推理时间。

表 3. 模型复杂度对比。FLOPs 表示浮点运算量。

方法	参数量	FLOPs	推理时间
完整帧卷积循环网络	12.54M	15.20G	35.42 ms
完整帧三维卷积网络	33.25M	38.64G	42.15 ms
全脸 RGB 时序网络	0.82M	0.05G	1.25 ms
RT-MRCPNet	0.94M	0.25G	2.38 ms

5 结论

本文提出 RT-MRCPNet，一种用于非接触式压力识别的轻量级区域-时间注意力多区域颜色脉动网络。该方法将人脸视频转化为紧凑的多区域 RGB 时序序列，使用共享时序编码器建模区域内部颜色动态，并通过时间注意力和区域注意力自适应聚合有效信息。在 subject-independent 协议下，RT-MRCPNet 达到 88.42% ACC、88.15% F1-score 和 91.54% AUC，优于 RGB 序列基线、传统 rPPG 特征基线和轻量视频基线。消融实验和复杂度分析表明，时间注意力与区域注意力能够带来互补增益，同时保持较低计算

开销。当前方法仍采用固定矩形 ROI 和二分类任务标签；未来工作将探索基于 landmarks 或三维人脸网格的区域定义、更细粒度的压力标注，以及与音频、眼动或接触式生理信号的多模态融合。

参考文献

1. Benezeth, Y., Li, P., Macwan, R., Nakamura, K., Gomez, R., Yang, F.: Remote heart rate variability for emotional state monitoring. In: Proceedings of the IEEE EMBS International Conference on Biomedical and Health Informatics. pp. 153–156 (2018)
2. Bondarenko, M., Menon, C., Elgendi, M.: The role of face regions in remote photoplethysmography for contactless heart rate monitoring. *npj Digital Medicine* **8**, 479 (2025). <https://doi.org/10.1038/s41746-025-01814-9>
3. Braun, B., McDuff, D., Baltrusaitis, T., Holz, C.: Video-based sympathetic arousal assessment via peripheral blood flow estimation. *Biomedical Optics Express* **14**(12), 6607–6628 (2023). <https://doi.org/10.1364/BOE.507949>
4. Braun, B., McDuff, D., Baltrusaitis, T., Strel, P., Moebus, M., Holz, C.: SympCam: Remote optical measurement of sympathetic arousal. In: Proceedings of the IEEE-EMBS International Conference on Biomedical and Health Informatics. p. 10913710 (2024). <https://doi.org/10.1109/BHI62660.2024.10913710>
5. Chaptoukaev, H., Strizhkova, V., Panariello, M., D'Alpaos, B., Reka, A., Manera, V., Thümmel, S., Ismailova, E., Evans, N.W.D., Brémond, F., Todisco, M., Zuluaga, M.A., Ferrari, L.M.: StressID: A multimodal dataset for stress identification. In: Advances in Neural Information Processing Systems. vol. 36 (2023)
6. Chen, W., McDuff, D.: Deepphys: Video-based physiological measurement using convolutional attention networks. In: Proceedings of the European Conference on Computer Vision. pp. 356–373 (2018)
7. de Haan, G., Jeanne, V.: Robust pulse rate from chrominance-based rPPG. *IEEE Transactions on Biomedical Engineering* **60**(10), 2878–2886 (2013). <https://doi.org/10.1109/TBME.2013.2266196>
8. Heimerl, A., Prajod, P., Mertes, S., Baur, T., Kraus, M., Liu, A., Risack, H., Rohleder, N., André, E., Becker, L.: The ForDigitStress dataset: A multi-modal dataset for automatic stress recognition. *IEEE Transactions on Affective Computing* pp. 1–17 (2024). <https://doi.org/10.1109/TAFFC.2024.3501400>
9. Huo, C., Yin, P., Fu, B.: MultiPhys: Heterogeneous fusion of Mamba and transformer for video-based multi-task physiological measurement. *Sensors* **25**(1), 100 (2025). <https://doi.org/10.3390/s25010100>
10. Joshi, J., Agaian, S.S., Cho, Y.: Factorizephys: Matrix factorization for multidimensional attention in remote physiological sensing. In: Advances in Neural Information Processing Systems. vol. 37 (2024)
11. Li, J., Peng, J.: DualPhysMamba: Efficient end-to-end network based on noise modeling for remote photoplethysmography measurement. *Applied Soft Computing* **187**, 114328 (2026). <https://doi.org/10.1016/j.asoc.2025.114328>
12. Liu, X., Fromm, J., Patel, S., McDuff, D.: Multi-task temporal shift attention networks for on-device contactless vitals measurement. In: Advances in Neural Information Processing Systems. vol. 33, pp. 19400–19411 (2020)
13. Liu, X., Hill, B., Jiang, Z., Patel, S., McDuff, D.: Efficientphys: Enabling simple, fast and accurate camera-based cardiac measurement. In: Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision. pp. 5008–5017 (2023)
14. Luo, C., Xie, Y., Yu, Z.: Physmamba: Efficient remote physiological measurement with slowfast temporal difference mamba. *arXiv preprint arXiv:2409.12031* (2024)
15. McDuff, D., Gontarek, S., Picard, R.W.: Remote measurement of cognitive stress via heart rate variability. In: Proceedings of the Annual International Conference of the IEEE Engineering in Medicine and Biology Society. pp. 2957–2960 (2014). <https://doi.org/10.1109/EMBC.2014.6944243>
16. Meziati Sabour, R., Benezeth, Y., De Oliveira, P., Chappe, J., Yang, F.: UBFC-Phys: A multimodal database for psychophysiological studies of social stress. *IEEE Transactions on Affective Computing* **14**(1), 622–636 (2023). <https://doi.org/10.1109/TAFFC.2021.3056960>
17. Nikolaiev, S., Telenyk, S., Tymoshenko, Y.: Non-contact video-based remote photoplethysmography for human stress detection. *Journal of Automation, Mobile Robotics and Intelligent Systems* **14**(2), 63–73 (2020). <https://doi.org/10.14313/JAMRIS/2-2020/21>
18. Pilz, C.S., Zaunseder, S., Krajewski, J., Blazek, V.: Local group invariance for heart rate estimation from face videos in the wild. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops pp. 1254–1262 (2018)
19. Wang, W., den Brinker, A.C., Stuijk, S., de Haan, G.: Algorithmic principles of remote PPG. *IEEE Transactions on Biomedical Engineering* **64**(7), 1479–1491 (2017). <https://doi.org/10.1109/TBME.2016.2609282>
20. Xiong, J., Ou, W., Liu, Z., Gou, J., Xiao, W., Liu, H.: Graphphys: Facial video-based physiological measurement with graph neural network. *Computers and Electrical Engineering* **113**, 109022 (2024). <https://doi.org/10.1016/j.compeleceng.2023.109022>
21. Xu, J., Song, C., Yue, Z., Ding, S.: Facial video-based non-contact stress recognition utilizing multi-task learning with peak attention. *IEEE Journal of Biomedical and Health Informatics* **28**(9), 5335–5346 (2024). <https://doi.org/10.1109/JBHI.2024.3412103>

22. Yu, Z., Li, X., Zhao, G.: Remote photoplethysmograph signal measurement from facial videos using spatio-temporal networks. In: Proceedings of the British Machine Vision Conference. pp. 1–12 (2019)
23. Yu, Z., Shen, Y., Shi, J., Zhao, H., Torr, P.H.S., Zhao, G.: Physformer: Facial video-based physiological measurement with temporal difference transformer. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. pp. 4186–4196 (2022)
24. Zhao, P., Sun, Q., Tian, X., Yang, Y., Tao, S., Cheng, J., Chen, J.: Toward motion robustness: A masked attention regularization framework in remote photoplethysmography. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. pp. 7829–7838 (2024)
25. Zhao, Y., Li, B., Wang, R., Wang, Y., Yan, J., Liu, F.: Remote estimation of heart rate based on multi-scale facial ROIs. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops pp. 388–389 (2020)
26. Zou, B., Guo, Z., Chen, J., Ma, H.: Rhythmformer: Extracting patterned remote photoplethysmography signals based on periodic sparse attention. Pattern Recognition **164**, 111511 (2025). <https://doi.org/10.1016/j.patcog.2025.111511>